混合高斯模型(Mixtures of Gaussians)和 EM 算法

JerryLead

csxulijie@gmail.com

这篇讨论使用期望最大化算法(Expectation-Maximization)来进行密度估计(density estimation)。

与 k-means 一样,给定的训练样本是{ $x^{(1)},...,x^{(m)}$ },我们将隐含类别标签用 $z^{(i)}$ 表示。与 k-means 的硬指定不同,我们首先认为 $z^{(i)}$ 是满足一定的概率分布的,这里我们认为满足多项式分布, $z^{(i)}$ ~Multinomial(\emptyset),其中 $p(z^{(i)}=j)=\emptyset_j,\ \emptyset_j\geq 0,\ \sum_{j=1}^k\emptyset_j=1,\ z^{(i)}$ 有 k 个值{1,...,k}可以选取。而且我们认为在给定 $z^{(i)}$ 后, $x^{(i)}$ 满足多值高斯分布,即($x^{(i)}|z^{(i)}=j$)~N(μ_i,Σ_i)。由此可以得到联合分布 $p(x^{(i)},z^{(i)})=p(x^{(i)}|z^{(i)})p(z^{(i)})$ 。

整个模型简单描述为对于每个样例 $x^{(i)}$,我们先从 k 个类别中按多项式分布抽取一个 $z^{(i)}$,然后根据 $z^{(i)}$ 所对应的 k 个多值高斯分布中的一个生成样例 $x^{(i)}$,。整个过程称作混合高斯模型。注意的是这里的 $z^{(i)}$ 仍然是隐含随机变量。模型中还有三个变量 \emptyset , μ 和 Σ 。最大似然估计为p(x,z)。对数化后如下:

$$\begin{array}{lcl} \ell(\phi,\mu,\Sigma) & = & \sum_{i=1}^{m} \log p(x^{(i)};\phi,\mu,\Sigma) \\ \\ & = & \sum_{i=1}^{m} \log \sum_{z^{(i)}=1}^{k} p(x^{(i)}|z^{(i)};\mu,\Sigma) p(z^{(i)};\phi). \end{array}$$

这个式子的最大值是不能通过前面使用的求导数为 0 的方法解决的,因为求的结果不是 close form。但是假设我们知道了每个样例的 $\mathbf{z}^{(i)}$,那么上式可以简化为:

$$\ell(\phi, \mu, \Sigma) = \sum_{i=1}^{m} \log p(x^{(i)}|z^{(i)}; \mu, \Sigma) + \log p(z^{(i)}; \phi).$$

这时候我们再来对Ø, μ和Σ进行求导得到:

$$\phi_{j} = \frac{1}{m} \sum_{i=1}^{m} 1\{z^{(i)} = j\},$$

$$\mu_{j} = \frac{\sum_{i=1}^{m} 1\{z^{(i)} = j\}x^{(i)}}{\sum_{i=1}^{m} 1\{z^{(i)} = j\}},$$

$$\Sigma_{j} = \frac{\sum_{i=1}^{m} 1\{z^{(i)} = j\}(x^{(i)} - \mu_{j})(x^{(i)} - \mu_{j})^{T}}{\sum_{i=1}^{m} 1\{z^{(i)} = j\}}.$$

 \emptyset_j 就是样本类别中 $\mathbf{z}^{(i)}=\mathbf{j}$ 的比率。 μ_j 是类别为 \mathbf{j} 的样本特征均值, Σ_j 是类别为 \mathbf{j} 的样例的特征的协方差矩阵。

实际上,当知道 $z^{(i)}$ 后,最大似然估计就近似于高斯判别分析模型(Gaussian discriminant analysis model)了。所不同的是 GDA 中类别 y 是伯努利分布,而这里的 z 是多项式分布,还有这里的每个样例都有不同的协方差矩阵,而 GDA 中认为只有一个。

之前我们是假设给定了 $\mathbf{z}^{(i)}$,实际上 $\mathbf{z}^{(i)}$ 是不知道的。那么怎么办呢?考虑之前提到的 EM 的思想,第一步是猜测隐含类别变量 \mathbf{z} ,第二步是更新其他参数,以获得最大的最大似然估计。用到这里就是:

循环下面步骤,直到收敛: {
$$(E \, ext{#}) \, ext{对于每} - ext{\wedge i } \, ext{n j, 计算}$$
 $w_j^{(i)} \coloneqq p(z^{(i)} = j | x^{(i)}; \Phi, \mu, \Sigma)$ $(M \, ext{$\#$})$,更新参数:
$$\phi_j \ := \ \frac{1}{m} \sum_{i=1}^m w_j^{(i)},$$

$$\mu_j \ := \ \frac{\sum_{i=1}^m w_j^{(i)} x^{(i)}}{\sum_{i=1}^m w_j^{(i)}},$$

$$\Sigma_j \ := \ \frac{\sum_{i=1}^m w_j^{(i)} (x^{(i)} - \mu_j) (x^{(i)} - \mu_j)^T}{\sum_{i=1}^m w_j^{(i)}}$$
 }

在 E 步中,我们将其他参数Φ, μ ,Σ看作常量,计算 $z^{(i)}$ 的后验概率,也就是估计隐含类别变量。估计好后,利用上面的公式重新计算其他参数,计算好后发现最大化最大似然估计时, $w_i^{(i)}$ 值又不对了,需要重新计算,周而复始,直至收敛。

 $w_i^{(i)}$ 的具体计算公式如下:

$$p(z^{(i)} = j | x^{(i)}; \phi, \mu, \Sigma) = \frac{p(x^{(i)} | z^{(i)} = j; \mu, \Sigma) p(z^{(i)} = j; \phi)}{\sum_{l=1}^{k} p(x^{(i)} | z^{(i)} = l; \mu, \Sigma) p(z^{(i)} = l; \phi)}$$

这个式子利用了贝叶斯公式。

这里我们使用 $\mathbf{w}_{i}^{(i)}$ 代替了前面的 $\mathbf{1}\{\mathbf{z}^{(i)}=\mathbf{j}\}$,由简单的 $\mathbf{0/1}$ 值变成了概率值。

对比 K-means 可以发现,这里使用了"软"指定,为每个样例分配的类别 $\mathbf{z}^{(i)}$ 是有一定的概率的,同时计算量也变大了,每个样例 i 都要计算属于每一个类别 j 的概率。与 K-means 相同的是,结果仍然是局部最优解。对其他参数取不同的初始值进行多次计算不失为一种好方法。

虽然之前再 K-means 中定性描述了 EM 的收敛性,仍然没有定量地给出,还有一般化 EM 的推导过程仍然没有给出。下一篇着重介绍这些内容。