# 独立成分分析(Independent Component Analysis)

JerryLead

csxulijie@gmail.com

## 1. 问题:

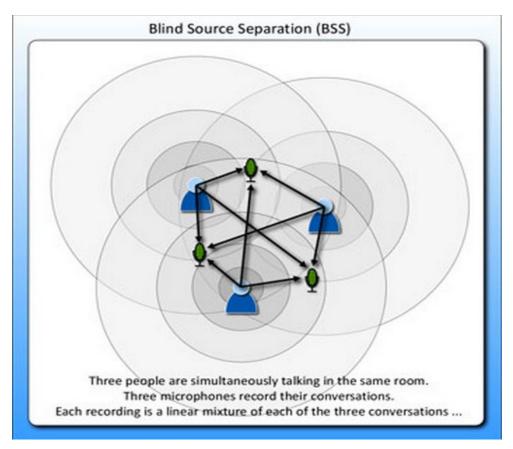
- 1、上节提到的 PCA 是一种数据降维的方法,但是只对符合高斯分布的样本点比较有效,那么对于其他分布的样本,有没有主元分解的方法呢?
- 2、经典的鸡尾酒宴会问题(cocktail party problem)。假设在 party 中有 n 个人,他们可以同时说话,我们也在房间中一些角落里共放置了 n 个声音接收器(Microphone)用来记录声音。宴会过后,我们从 n 个麦克风中得到了一组数据 $\{x^{(i)}(x_1^{(i)},x_2^{(i)},...,x_n^{(i)});i=1,...,m\}$ ,i 表示采样的时间顺序,也就是说共得到了 m 组采样,每一组采样都是 n 维的。我们的目标是单单从这 m 组采样数据中分辨出每个人说话的信号。

将第二个问题细化一下,有 n 个信号源s  $(s_1,s_2,...,s_n)^T$ ,s  $\in \mathbb{R}^n$ ,每一维都是一个人的声音信号,每个人发出的声音信号独立。A 是一个未知的混合矩阵(mixing matrix),用来组合叠加信号 s,那么

$$x = As$$

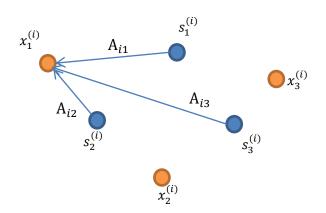
 ${\bf x}$  的意义在上文解释过,这里的  ${\bf x}$  不是一个向量,是一个矩阵。其中每个列向量是 ${\bf x}^{(i)}$ ,  ${\bf x}^{(i)}=A{\bf s}^{(i)}$ 

表示成图就是



这张图来自

http://amouraux.webnode.com/research-interests/research-interests-erp-analysis/blind-source-separation-bss-of-erps-using-independent-component-analysis-ica/



 $x^{(i)}$ 的每个分量都由 $s^{(i)}$ 的分量线性表示。A 和 s 都是未知的,x 是已知的,我们要想办法根据 x 来推出 s。这个过程也称作为盲信号分离。

令
$$W = A^{-1}$$
, 那么 
$$s^{(i)} = A^{-1}x^{(i)} = Wx^{(i)}$$

将 W 表示成

$$W = \left[ \begin{array}{c} -w_1^T - \\ \vdots \\ -w_n^T - \end{array} \right].$$

其中 $\mathbf{w}_i \in \mathbb{R}^n$ ,其实就是将 $\mathbf{w}_i$ 写成行向量形式。那么得到:

$$s_i^{(i)} = w_i^T x^{(i)}$$

### 2. ICA 的不确定性(ICA ambiguities)

由于 w 和 s 都不确定,那么在没有先验知识的情况下,无法同时确定这两个相关参数。比如上面的公式 s=wx。当 w 扩大两倍时, s 只需要同时扩大两倍即可,等式仍然满足,因此无法得到唯一的 s。同时如果将人的编号打乱,变成另外一个顺序,如上图的蓝色节点的编号变为 3,2,1,那么只需要调换 A 的列向量顺序即可,因此也无法单独确定 s。这两种情况称为原信号不确定。

还有一种 ICA 不适用的情况,那就是信号不能是高斯分布的。假设只有两个人发出的声音信号符合多值正态分布, $s\sim N(0,I)$ ,I 是 2\*2 的单位矩阵,s 的概率密度函数就不用说了吧,以均值 0 为中心,投影面是椭圆的山峰状(参见多值高斯分布)。因为x=As,因此,x也是高斯分布的,均值为 0,协方差为 $E[xx^T]=E[Ass^TA^T]=AA^T$ 。

令 R 是正交阵( $RR^T = R^TR = I$ ),A' = AR。如果将 A 替换成 A'。那么x' = A's。s 分布没变,因此 x'仍然是均值为 0,协方差 $E[x'(x')^T] = E[A'ss^T(A')^T] = E[ARss^T(AR)^T] = ARR^TA^T = AA^T$ 。

因此,不管混合矩阵是 A 还是 A', x 的分布情况是一样的,那么就无法确定混合矩阵,也就无法确定原信号。

### 3. 密度函数和线性变换

在讨论 ICA 具体算法之前,我们先来回顾一下概率和线性代数里的知识。

假设我们的随机变量 s 有概率密度函数 $p_s(s)$ (连续值是概率密度函数,离散值是概率)。为了简单,我们再假设 s 是实数,还有一个随机变量 x=As,A 和 x 都是实数。 $\Diamond p_x$ 是 x 的概率密度,那么怎么求 $p_x$ ?

令 $W = A^{-1}$ ,首先将式子变换成s = Wx,然后得到 $p_x(x) = p_s(Ws)$ ,求解完毕。可惜这种方法是错误的。比如 s 符合均匀分布的话( $s\sim Uniform[0,1]$ ),那么 s 的概率密度是 $p_s(s) = 1\{0 \le s \le 1\}$ ,现在令 A=2,即 x=2s,也就是说 x 在[0,2]上均匀分布,可知 $p_x(x) = 0.5$ 。然而,前面的推导会得到 $p_x(x) = p_s(0.5s) = 1$ 。正确的公式应该是

$$p_x(x) = p_s(Wx)|W|$$

推导方法

$$F_X(x) = P(X \le x) = P(AS \le x) = P(S \le Wx) = F_S(Wx)$$
  
 $p_X(x) = F'_X(x) = F'_S(Wx) = p_S(Wx)|W|$ 

更一般地,如果s是向量,A可逆的方阵,那么上式子仍然成立。

#### 4. ICA 算法

ICA 算法归功于 Bell 和 Sejnowski,这里使用最大似然估计来解释算法,原始的论文中使用的是一个复杂的方法 Infomax principal。

我们假定每个 $s_i$ 有概率密度 $p_s$ ,那么给定时刻原信号的联合分布就是

$$p(s) = \prod_{i=1}^{n} p_s(s_i)$$

这个公式代表一个假设前提:每个人发出的声音信号各自独立。有了p(s),我们可以求得p(x)

$$p(x) = p_s(Wx)|W| = |W| \prod_{i=1}^{n} p_s(w_i^T x)$$

左边是每个采样信号 x (n 维向量)的概率,右边是每个原信号概率的乘积的 | W | 倍。

前面提到过,如果没有先验知识,我们无法求得 W 和 s。因此我们需要知道 $p_s(s_i)$ ,我们打算选取一个概率密度函数赋给 s,但是我们不能选取高斯分布的密度函数。在概率论里我们知道密度函数 p(x)由累计分布函数(cdf)F(x)求导得到。F(x)要满足两个性质是:单调递增和在[0,1]。我们发现 sigmoid 函数很适合,定义域负无穷到正无穷,值域 0 到 1,缓慢递增。我们假定 s 的累积分布函数符合 sigmoid 函数

$$g(s) = \frac{1}{1 + e^{-s}}$$

求导后

$$p_s(s) = g'(s) = \frac{e^s}{(1 + e^s)^2}$$

这就是s的密度函数。这里s是实数。

如果我们预先知道 s 的分布函数,那就不用假设了,但是在缺失的情况下,sigmoid 函数能够在大多数问题上取得不错的效果。由于上式中 $p_s(s)$ 是个对称函数,因此 E[s]=0(s 的均值为 0),那么 E[x]=E[As]=0,x 的均值也是 0。

知道了 $p_s(s)$ ,就剩下 W 了。给定采样后的训练样本 $\{x^{(i)}(x_1^{(i)},x_2^{(i)},...,x_n^{(i)}); i=1,...,m\}$ ,样本对数似然估计如下:

使用前面得到的 x 的概率密度函数,得

$$\ell(W) = \sum_{i=1}^{m} \left( \sum_{j=1}^{n} \log g'(w_j^T x^{(i)}) + \log |W| \right).$$

大括号里面是 $p(x^{(i)})$ 。

接下来就是对 W 求导了,这里牵涉一个问题是对行列式|W|进行求导的方法,属于矩阵微积分。这里先给出结果,在文章最后再给出推导公式。

$$\nabla_W |W| = |W|(W^{-1})^T$$

最终得到的求导后公式如下, $\log g'(s)$ 的导数为1-2g(s)(可以自己验证):

$$W := W + \alpha \left( \begin{bmatrix} 1 - 2g(w_1^T x^{(i)}) \\ 1 - 2g(w_2^T x^{(i)}) \\ \vdots \\ 1 - 2g(w_n^T x^{(i)}) \end{bmatrix} x^{(i)^T} + (W^T)^{-1} \right),$$

其中α是梯度上升速率,人为指定。

当迭代求出 W 后,便可得到 $\mathbf{s}^{(i)} = Wx^{(i)}$ 来还原出原始信号。

**注意**: 我们计算最大似然估计时,假设了 $x^{(i)}$ 与 $x^{(j)}$ 之间是独立的,然而对于语音信号或者其他具有时间连续依赖特性(比如温度)上,这个假设不能成立。但是在数据足够多时,假设独立对效果影响不大,同时如果事先打乱样例,并运行随机梯度上升算法,那么能够加快收敛速度。

回顾一下鸡尾酒宴会问题,s 是人发出的信号,是连续值,不同时间点的 s 不同,每个人发出的信号之间独立( $s_i$ 和 $s_j$ 之间独立)。s 的累计概率分布函数是 sigmoid 函数,但是所有人发出声音信号都符合这个分布。A(W 的逆阵)代表了 s 相对于 x 的位置变化,x 是 s 和 A 变化后的结果。

# 5. 实例

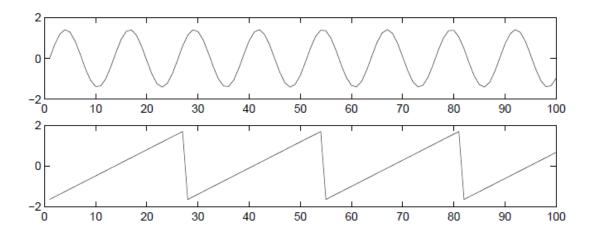


Figure 1: The original signals.

s=2 时的原始信号

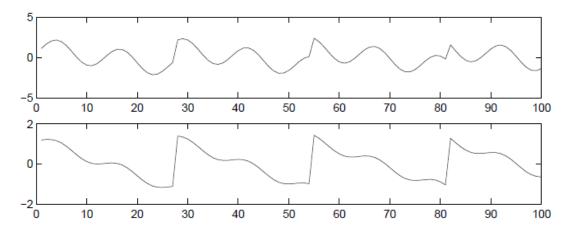
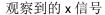
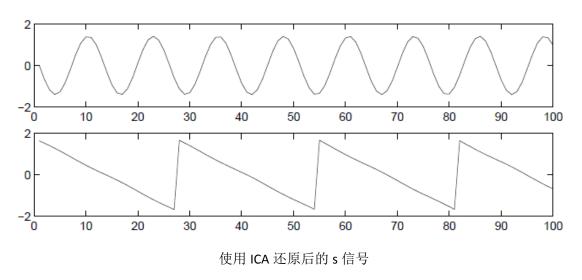


Figure 2: The observed mixtures of the source signals in Fig. 1.





# 6. 行列式的梯度

对行列式求导,设矩阵 A 是 n×n 的,我们知道行列式与代数余子式有关,

$$|A| = \sum_{i=1}^{n} (-1)^{i+j} A_{ij} |A_{\setminus i,\setminus j}| \quad \text{(for any } j \in 1,\dots,n)$$

 $A_{\backslash i,\backslash j}$ 是去掉第 i 行第 j 列后的余子式,那么对 $A_{k,l}$ 求导得

$$\frac{\partial}{\partial A_{k\ell}}|A| = \frac{\partial}{\partial A_{k\ell}} \sum_{i=1}^{n} (-1)^{i+j} A_{ij} |A_{\langle i, \backslash j}| = (-1)^{k+\ell} |A_{\langle k, \backslash \ell}| = (\operatorname{adj}(A))_{\ell k}.$$

adj(A)跟我们线性代数中学的A\*是一个意思,因此

$$\nabla_A |A| = (\operatorname{adj}(A))^T = |A|A^{-T}.$$

### 7. ICA 算法扩展描述

上面介绍的内容基本上是讲义上的,与我看的另一篇《Independent Component Analysis: Algorithms and Applications》(Aapo Hyvärinen and Erkki Oja)有点出入。下面总结一下这篇文章里提到的一些内容(有些我也没看明白)。

首先里面提到了一个与"独立"相似的概念"不相关(uncorrelated)"。Uncorrelated 属于部分独立,而不是完全独立,怎么刻画呢?

如果随机变量 $y_1$ 和 $y_2$ 是独立的,当且仅当 $p(y_1,y_2) = p(y_1)p(y_2)$ 。

如果随机变量 $y_1$ 和 $y_2$ 是不相关的, 当且仅当 $E(y_1,y_2) = E(y_1)E(y_2)$ 

第二个不相关的条件要比第一个独立的条件"松"一些。因为独立能推出不相关,不相 关推不出独立。

证明如下:

$$p_1(y_1) = \int p(y_1, y_2) dy_2,$$

$$p(y_1,y_2) = p_1(y_1)p_2(y_2).$$

$$\begin{split} E\{h_1(y_1)h_2(y_2)\} &= \int \int h_1(y_1)h_2(y_2)p(y_1,y_2)dy_1dy_2 \\ &= \int \int h_1(y_1)p_1(y_1)h_2(y_2)p_2(y_2)dy_1dy_2 = \int h_1(y_1)p_1(y_1)dy_1 \int h_2(y_2)p_2(y_2)dy_2 \\ &= E\{h_1(y_1)\}E\{h_2(y_2)\}. \end{split}$$

反过来不能推出。

比如, $y_1$ 和 $y_2$ 的联合分布如下(0,1),(0,-1),(1,0),(-1,0)。

$$E(y_1, y_2) = E(y_1)E(y_2) = 0$$

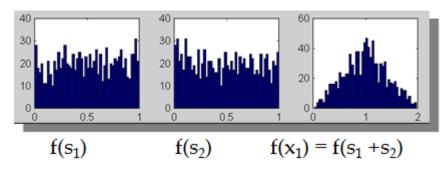
因此y<sub>1</sub>和y<sub>2</sub>不相关,但是

$$E(y_1^2 y_1^2) = 0 \neq \frac{1}{4} = E(y_1^2) E(y_2^2)$$

因此y<sub>1</sub>和y<sub>2</sub>不满足上面的积分公式,y<sub>1</sub>和y<sub>2</sub>不是独立的。

上面提到过,如果 $\mathbf{s}^{(i)}$ 是高斯分布的,A 是正交的,那么 $\mathbf{x}^{(i)}$ 也是高斯分布的,且 $\mathbf{x}^{(i)}$ 与 $\mathbf{x}^{(j)}$ 之间是独立的。那么无法确定 A,因为任何正交变换都可以让 $\mathbf{x}^{(i)}$ 达到同分布的效果。但是如果 $\mathbf{s}^{(i)}$ 中只有一个分量是高斯分布的,仍然可以使用 ICA。

那么 ICA 要解决的问题变为:如何从 x 中推出 s,使得 s 最不可能满足高斯分布?中心极限定理告诉我们:大量独立同分布随机变量之和满足高斯分布。



我们一直假设的是 $\mathbf{x}^{(i)}$ 是由独立同分布的主元 $\mathbf{s}^{(i)}$ 经过混合矩阵  $\mathbf{A}$ 生成。那么为了求 $\mathbf{s}^{(i)}$ ,我们需要计算 $\mathbf{s}^{(i)}$ 的每个分量 $\mathbf{y}_j^{(i)} = w_j^T \mathbf{x}^{(i)}$ 。定义 $\mathbf{z}_j = A^T w_j$ ,那么 $\mathbf{y}_j^{(i)} = w_j^T \mathbf{x}^{(i)} = w_j^T \mathbf{A} \mathbf{s}^{(i)} = \mathbf{z}_j^T \mathbf{s}^{(i)}$ ,之所以这么麻烦再定义  $\mathbf{z}$  是想说明一个关系,我们想通过整出一个 $\mathbf{w}_j$ 来对 $\mathbf{x}^{(i)}$ 进行线性组合,得出  $\mathbf{y}$ 。而我们不知道得出的  $\mathbf{y}$  是否是真正的  $\mathbf{s}$  的分量,但我们知道  $\mathbf{y}$  是  $\mathbf{s}$  的真正分量的线性组合。由于我们不能使  $\mathbf{s}$  的分量成为高斯分布,因此我们的目标求是让  $\mathbf{y}$  (也就是 $\mathbf{w}_j^T \mathbf{x}^{(i)}$ )最不可能是高斯分布时的  $\mathbf{w}$ 。

那么问题递归到如何度量y是否是高斯分布的了。

一种度量方法是 kurtosis 方法, 公式如下:

$$kurt(y) = E\{y^4\} - 3(E\{y^2\})^2$$

如果 y 是高斯分布,那么该函数值为 0,否则绝大多数情况下值不为 0。 但这种度量方法不怎么好,有很多问题。看下一种方法:

负熵(Negentropy)度量方法。

我们在信息论里面知道对于离散的随机变量Y,其熵是

$$H(Y) = -\sum_{i} P(Y = a_i) \log P(Y = a_i)$$

连续值时是

$$H(\mathbf{y}) = -\int f(\mathbf{y}) \log f(\mathbf{y}) d\mathbf{y}.$$

在信息论里有一个强有力的结论是:高斯分布的随机变量是同方差分布中熵最大的。也就是说对于一个随机变量来说,满足高斯分布时,最随机。

定义负熵的计算公式如下:

$$J(\mathbf{y}) = H(\mathbf{y}_{gauss}) - H(\mathbf{y})$$

也就是随机变量 y 相对于高斯分布时的熵差,这个公式的问题就是直接计算时较为复杂,一般采用逼近策略。

$$J(y) \approx \frac{1}{12} E\{y^3\}^2 + \frac{1}{48} \operatorname{kurt}(y)^2$$

这种逼近策略不够好,作者提出了基于最大熵的更优的公式:

$$J(y) \approx \sum_{i=1}^{p} k_i [E\{G_i(y)\} - E\{G_i(v)\}]^2$$

之后的 FastICA 就基于这个公式。

另外一种度量方法是最小互信息方法:

$$I(y_1, y_2, ..., y_m) = \sum_{i=1}^m H(y_i) - H(y).$$

这个公式可以这样解释,前一个 H 是 $y_i$ 的编码长度(以信息编码的方式理解),第二个 H 是 y 成为随机变量时的平均编码长度。之后的内容包括 FastICA 就不再介绍了,我也没看懂。

## 8. ICA 的投影追踪解释(Projection Pursuit)

投影追踪在统计学中的意思是去寻找多维数据的"interesting"投影。这些投影可用在数据可视化、密度估计和回归中。比如在一维的投影追踪中,我们寻找一条直线,使得所有的数据点投影到直线上后,能够反映出数据的分布。然而我们最不想要的是高斯分布,最不像高斯分布的数据点最 interesting。这个与我们的 ICA 思想是一直的,寻找独立的最不可能是高斯分布的 s。

在下图中,主元是纵轴,拥有最大的方差,但最 interesting 的是横轴,因为它可以将两个类分开(信号分离)。



### 9. ICA 算法的前处理步骤

- 1、中心化: 也就是求 x 均值,然后让所有 x 减去均值,这一步与 PCA 一致。
- 2、**漂白:**目的是将 x 乘以一个矩阵变成 $\tilde{x}$ ,使得 $\tilde{x}$ 的协方差矩阵是I。解释一下吧,原始的向量是 x。转换后的是 $\tilde{x}$ 。

 $\tilde{x}$ 的协方差矩阵是I,即

$$E\{\tilde{\mathbf{x}}\tilde{\mathbf{x}}^T\} = \mathbf{I}.$$

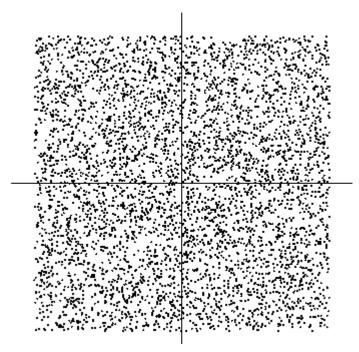
我们只需用下面的变换,就可以从x得到想要的 $\tilde{x}$ 。

$$\tilde{\mathbf{x}} = \mathbf{E}\mathbf{D}^{-1/2}\mathbf{E}^T\mathbf{x}$$

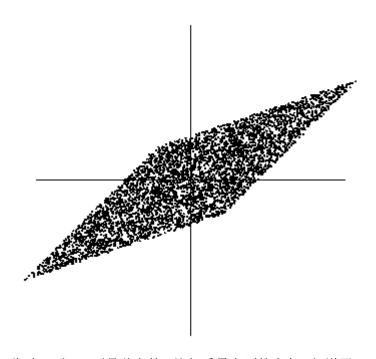
其中使用特征值分解来得到 E(特征向量矩阵)和 D(特征值对角矩阵),计算公式为  $E\{xx^T\} = EDE^T$ 

下面用个图来直观描述一下:

假设信号源 s1 和 s2 是独立的,比如下图横轴是 s1,纵轴是 s2,根据 s1 得不到 s2。

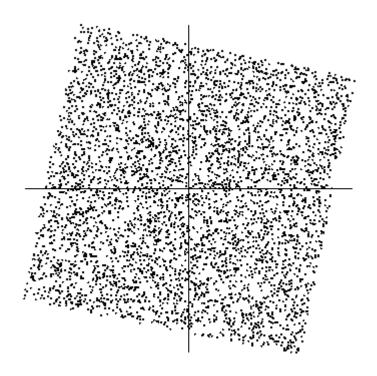


我们只知道他们合成后的信号 x,如下



此时 x1 和 x2 不是独立的(比如看最上面的尖角,知道了 x1 就知道了 x2)。那么直接代入我们之前的极大似然概率估计会有问题,因为我们假定 x 是独立的。

因此,漂白这一步为了让 x 独立。漂白结果如下:



可以看到数据变成了方阵,在兖的维度上已经达到了独立。

然而这时 x 分布很好的情况下能够这样转换, 当有噪音时怎么办呢?可以先使用前面提到的 PCA 方法来对数据进行降维, 滤去噪声信号, 得到 k 维的正交向量, 然后再使用 ICA。

# 10. 小结

ICA 的盲信号分析领域的一个强有力方法,也是求非高斯分布数据隐含因子的方法。从 之前我们熟悉的样本-特征角度看,我们使用 ICA 的前提条件是,认为样本数据由独立非高 斯分布的隐含因子产生,隐含因子个数等于特征数。而 PCA 认为特征是由 k 个正交的特征 (也可看作是隐含因子)生成的。同是因子分析,一个用来更适合用来还原信号(因为信号比较有规律,经常不是高斯分布的),一个更适合用来降维(用那么多特征干嘛,k 个正交的即可)。有时候也需要组合两者一起使用。这段是我的个人理解,仅供参考。