# 线性判别分析(Linear Discriminant Analysis)

JerryLead

csxulijie@gmail.com

#### 1. 问题

之前我们讨论的 PCA、ICA 也好,对样本数据来言,可以是没有类别标签 y 的。回想我们做回归时,如果特征太多,那么会产生不相关特征引入、过度拟合等问题。我们可以使用 PCA 来降维,但 PCA 没有将类别标签考虑进去,属于无监督的。

比如回到上次提出的文档中含有"learn"和"study"的问题,使用 PCA 后,也许可以将这两个特征合并为一个,降了维度。但假设我们的类别标签 y 是判断这篇文章的 topic 是不是有关学习方面的。那么这两个特征对 y 几乎没什么影响,完全可以去除。

再举一个例子,假设我们对一张 100\*100 像素的图片做人脸识别,每个像素是一个特征,那么会有 10000 个特征,而对应的类别标签 y 仅仅是 0/1 值,1 代表是人脸。这么多特征不仅训练复杂,而且不必要特征对结果会带来不可预知的影响,但我们想得到降维后的一些最佳特征(与 y 关系最密切的),怎么办呢?

### 2. 线性判别分析(二类情况)

回顾我们之前的 logistic 回归方法,给定 m 个 n 维特征的训练样例 $x^{(i)}\{x_1^{(i)},x_2^{(i)},...,x_n^{(i)}\}$ (i 从 1 到 m),每个 $x^{(i)}$ 对应一个类标签 $y^{(i)}$ 。我们就是要学习出参数 $\theta$ ,使得 $y^{(i)}=g(\theta)^Tx^{(i)}$ (g 是 sigmoid 函数)。

现在只考虑二值分类情况,也就是 v=1 或者 v=0。

为了方便表示,我们先换符号重新定义问题,给定特征为 d 维的 N 个样例, $x^{(i)}\{x_1^{(i)},x_2^{(i)},...,x_d^{(i)}\}$ ,其中有 $\mathbf{N}_1$ 个样例属于类别 $\mathbf{\omega}_1$ ,另外 $\mathbf{N}_2$ 个样例属于类别 $\mathbf{\omega}_2$ 。

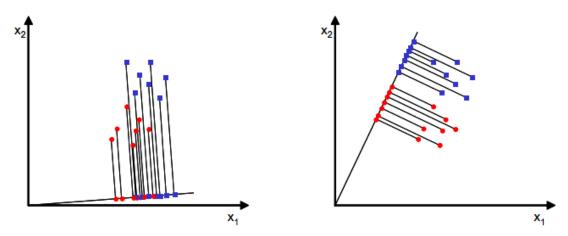
现在我们觉得原始特征数太多,想将 d 维特征降到**只有一维**,而又要保证类别能够"清晰"地反映在低维数据上,也就是这一维就能决定每个样例的类别。

我们将这个最佳的向量称为w(d维),那么样例x(d维)到w上的投影可以用下式来计算

$$y = w^T x$$

这里得到的 y 值不是 0/1 值, 而是 x 投影到直线上的点到原点的距离。

当x是二维的,我们就是要找一条直线(方向为w)来做投影,然后寻找最能使样本点分离的直线。如下图:



从直观上来看,右图比较好,可以很好地将不同类别的样本点分离。

接下来我们从定量的角度来找到这个最佳的 w。 首先我们寻找每类样例的均值(中心点),这里 i 只有两个

$$\mu_i = \frac{1}{N_i} \sum_{x \in \omega_i} x$$

由于 x 到 w 投影后的样本点均值为

$$\widetilde{\mu_i} = \frac{1}{N_i} \sum_{y \in \omega_i} y = \frac{1}{N_i} \sum_{x \in \omega_i} w^T x = w^T \mu_i$$

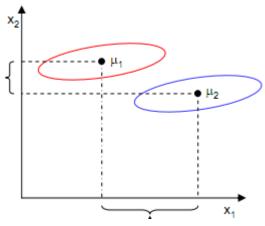
由此可知,投影后的的均值也就是样本中心点的投影。

什么是最佳的直线(w)呢?我们首先发现,能够使投影后的两类样本中心点尽量分离的直线是好的直线,定量表示就是:

$$J(w) = |\widetilde{\mu_1} - \widetilde{\mu_2}| = |w^T(\mu_1 - \mu_2)|$$

J(w)越大越好。

但是只考虑 J(w)行不行呢? 不行,看下图



样本点均匀分布在椭圆里,投影到横轴 x1 上时能够获得更大的中心点间距 J(w),但是由于有重叠,x1 不能分离样本点。投影到纵轴 x2 上,虽然 J(w)较小,但是能够分离样本点。因此我们还需要考虑样本点之间的方差,方差越大,样本点越难以分离。

我们使用另外一个度量值,称作散列值(scatter),对投影后的类求散列值,如下

$$\widetilde{s_i}^2 = \sum_{y \in \omega_i} (y - \widetilde{\mu}_i)^2$$

从公式中可以看出,只是少除以样本数量的方差值,散列值的几何意义是样本点的密集 程度,值越大,越分散,反之,越集中。

而我们想要的投影后的样本点的样子是:不同类别的样本点越分开越好,同类的越聚集越好,也就是均值差越大越好,散列值越小越好。正好,我们可以使用 J(w)和 S 来度量,最终的度量公式是

$$J(w) = \frac{|\widetilde{\mu_1} - \widetilde{\mu_2}|^2}{\widetilde{S_1}^2 + \widetilde{S_2}^2}$$

接下来的事就比较明显了,我们只需寻找使 J(w)最大的 w 即可。

先把散列值公式展开

$$\widetilde{s_i}^2 = \sum_{y \in \omega_i} (y - \widetilde{\mu}_i)^2 = \sum_{x \in \omega_i} (w^T x - w^T \mu_i)^2 = \sum_{x \in \omega_i} w^T (x - \mu_i) (x - \mu_i)^T w$$

我们定义上式中中间那部分

$$S_i = \sum_{x \in \omega_i} (x - \mu_i)(x - \mu_i)^T$$

这个公式的样子不就是少除以样例数的协方差矩阵么,称为散列矩阵(scatter matrices)

我们继续定义

$$S_w = S_1 + S_2$$

Sw称为 Within-class scatter matrix。

那么回到上面 $\tilde{s_i}^2$ 的公式,使用 $S_i$ 替换中间部分,得

$$\widetilde{\mathbf{s}_{i}}^{2} = \mathbf{w}^{\mathrm{T}} \mathbf{S}_{i} \mathbf{w}$$

$$\widetilde{\mathbf{s}_1}^2 + \widetilde{\mathbf{s}_2}^2 = \mathbf{w}^{\mathrm{T}} \mathbf{S}_{\mathbf{w}} \mathbf{w}$$

然后,我们展开分子

$$\left(\widetilde{\boldsymbol{\mu}}_{\!1} - \widetilde{\boldsymbol{\mu}}_{\!2}\right)^{\!2} = \! \left(\boldsymbol{w}^{\mathsf{T}} \boldsymbol{\mu}_{\!1} - \boldsymbol{w}^{\mathsf{T}} \boldsymbol{\mu}_{\!2}\right)^{\!2} = \boldsymbol{w}^{\mathsf{T}} \underbrace{\left(\boldsymbol{\mu}_{\!1} - \boldsymbol{\mu}_{\!2}\right) \!\! \left(\boldsymbol{\mu}_{\!1} - \boldsymbol{\mu}_{\!2}\right)^{\!\mathsf{T}}}_{\widetilde{\boldsymbol{S}_{\scriptscriptstyle D}}} \boldsymbol{w} = \boldsymbol{w}^{\mathsf{T}} \boldsymbol{S}_{\scriptscriptstyle B} \boldsymbol{w}$$

 $S_B$ 称为 **Between**-class scatter,是两个向量的外积,虽然是个矩阵,但秩为 1。

那么 J(w)最终可以表示为

$$J(w) = \frac{w^{T}S_{B}w}{w^{T}S_{w}w}$$

在我们求导之前,需要对分母进行归一化,因为不做归一的话, $\mathbf{w}$  扩大任何倍,都成立,我们就无法确定  $\mathbf{w}$ 。因此我们打算令 $||\mathbf{w}^{\mathrm{T}}\mathbf{S}_{\mathbf{w}}\mathbf{w}||=1$ ,那么加入拉格朗日乘子后,求导

$$c(w) = w^{t} S_{BW} - \lambda (w^{t} S_{WW} - 1)$$

$$\Rightarrow \frac{dc}{dw} = 2S_{BW} - 2\lambda S_{WW} = 0$$

$$\Rightarrow S_{BW} = \lambda S_{WW}$$

其中用到了矩阵微积分,求导时可以简单地把 $w^{\mathrm{T}}S_{w}w$ 当做 $S_{w}w^{2}$ 看待。如果 $S_{w}$ 可逆,那么将求导后的结果两边都乘以 $S_{w}^{-1}$ ,得

$$Sw^{-1}S_Bw = \lambda w$$

这个可喜的结果就是 w 就是矩阵 $S_w^{-1}S_B$ 的特征向量了。这个公式称为 Fisher linear discrimination。

等等,让我们再观察一下,发现前面Sa的公式

$$S_B = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T$$

那么

$$S_B W = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T W = (\mu_1 - \mu_2) * \lambda_W$$

代入最后的特征值公式得

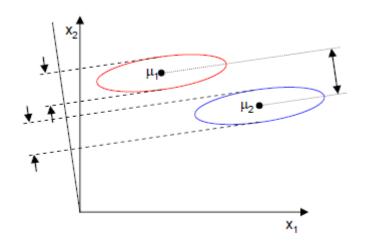
$$S_w^{-1}S_R w = S_w^{-1}(\mu_1 - \mu_2) * \lambda_w = \lambda w$$

由于对w扩大缩小任何倍不影响结果,因此可以约去两边的未知常数 $\lambda$ 和 $\lambda_w$ ,得到

$$w = S_w^{-1}(\mu_1 - \mu_2)$$

至此,我们只需要求出原始样本的均值和方差就可以求出最佳的方向 w, 这就是 Fisher 于 1936 年提出的线性判别分析。

看上面二维样本的投影结果图:



### 3. 线性判别分析(多类情况)

前面是针对只有两个类的情况,假设类别变成多个了,那么要怎么改变,才能保证投影 后类别能够分离呢?

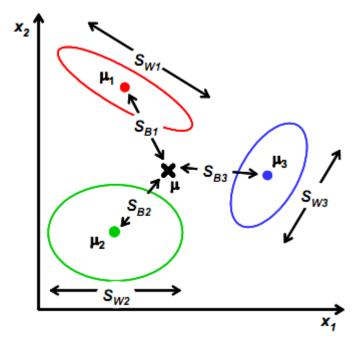
我们之前讨论的是如何将 d 维降到一维,现在类别多了,一维可能已经不能满足要求。假设我们有 C 个类别,需要 K 维向量(或者叫做基向量)来做投影。

将这 K 维向量表示为W =  $[w_1|w_2|...|w_K]$ 。

我们将样本点在这 K 维向量投影后结果表示为 $[y_1,y_2,...,y_K]$ ,有以下公式成立

$$y_i = w_i^T x$$
$$y = W^T x$$

为了像上节一样度量 J(w), 我们打算仍然从类间散列度和类内散列度来考虑。 当样本是二维时, 我们从几何意义上考虑:



其中 $\mu_i$ 和 $S_w$ 与上节的意义一样, $S_{w1}$ 是类别 1 里的样本点相对于该类中心点 $\mu_1$ 的散列程度。 $S_{B1}$ 变成类别 1 中心点相对于样本中心点 $\mu$ 的协方差矩阵,即类 1 相对于 $\mu$ 的散列程度。

Sw为

$$S_w = \sum_{i=1}^C S_{wi}$$

 $S_{wi}$ 的计算公式不变,仍然类似于类内部样本点的协方差矩阵

$$S_{wi} = \sum_{x \in \omega_i} (x - \mu_i)(x - \mu_i)^T$$

 $S_B$ 需要变,原来度量的是两个均值点的散列情况,现在度量的是每类均值点相对于样本中心的散列情况。类似于将 $\mu_i$ 看作样本点, $\mu$ 是均值的协方差矩阵,如果某类里面的样本点较多,那么其权重稍大,权重用 Ni/N 表示,但由于 J(w)对倍数不敏感,因此使用 Ni。

$$S_B = \sum_{i=1}^{C} N_i (\mu_i - \mu)(\mu_i - \mu)^T$$

其中

$$\mu = \frac{1}{N} \sum_{\forall x} x = \frac{1}{N} \sum_{x \in \omega_i} N_i \mu_i$$

μ是所有样本的均值。

上面讨论的都是在投影前的公式变化,但真正的 J(w)的分子分母都是在投影后计算的。 下面我们看样本点投影后的公式改变:

这两个是第i类样本点在某基向量上投影后的均值计算公式。

$$\widetilde{\mu_i} = \frac{1}{N_i} \sum_{y \in \omega_i} y$$

$$1 \sum$$

$$\tilde{\mu} = \frac{1}{N} \sum_{\forall y} y$$

下面两个是在某基向量上投影后的 $S_w$ 和 $S_B$ 

$$\widetilde{S_w} = \sum_{i=1}^{C} \sum_{y \in \omega_i} (y - \widetilde{\mu_i})(y - \widetilde{\mu_i})^T$$

$$\widetilde{S_B} = \sum_{i=1}^C N_i (\widetilde{\mu}_i - \widetilde{\mu}) (\widetilde{\mu}_i - \widetilde{\mu})^T$$

其实就是将 $\mu$ 换成了 $\tilde{\mu}$ 。

综合各个投影向量(w)上的 $\widetilde{S_w}$ 和 $\widetilde{S_B}$ ,更新这两个参数,得到

$$\widetilde{S_W} = W^T S_W W$$
$$\widetilde{S_B} = W^T S_B W$$

W 是基向量矩阵, $\widetilde{S_w}$ 是投影后的各个类内部的散列矩阵之和, $\widetilde{S_B}$ 是投影后各个类中心相对于全样本中心投影的散列矩阵之和。

回想我们上节的公式 J(w), 分子是两类中心距, 分母是每个类自己的散列度。现在投影方向是多维了(好几条直线), 分子需要做一些改变, 我们不是求两两样本中心距之和(这个对描述类别间的分散程度没有用), 而是求每类中心相对于全样本中心的散列度之和。

然而,最后的J(w)的形式是

$$J(w) = \frac{|\widetilde{S_B}|}{|\widetilde{S_W}|} = \frac{|W^T S_B W|}{|W^T S_w W|}$$

由于我们得到的分子分母都是散列矩阵,要将矩阵变成实数,需要取行列式。又因为行列式的值实际上是矩阵特征值的积,一个特征值可以表示在该特征向量上的发散程度。因此我们使用行列式来计算(此处我感觉有点牵强,道理不是那么有说服力)。

整个问题又回归为求 J(w)的最大值了,我们固定分母为 1,然后求导,得出最后结果(我翻查了很多讲义和文章,没有找到求导的过程)

$$S_B w_i = \lambda S_w w_i$$

与上节得出的结论一样

$$S_w^{-1}S_Rw_i = \lambda w_i$$

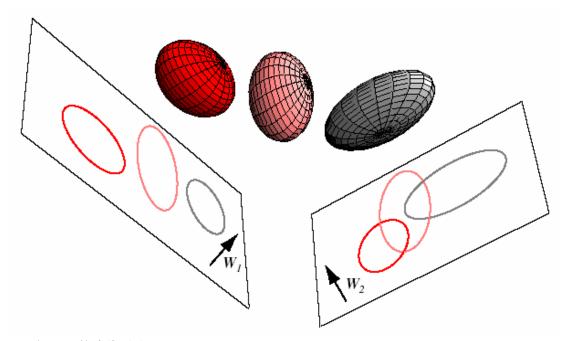
最后还归结到了求矩阵的特征值上来了。首先求出 $S_w^1S_B$ 的特征值,然后取前 K 个特征向量组成 W 矩阵即可。

**注意:** 由于 $S_B$ 中的( $\mu_i - \mu$ ) 秩为 1,因此 $S_B$ 的秩至多为 C(矩阵的秩小于等于各个相加矩阵的秩的和)。由于知道了前 C-1 个 $\mu_i$ 后,最后一个 $\mu_c$ 可以有前面的 $\mu_i$ 来线性表示,因此 $S_B$ 的 秩至多为 C-1。那么 K 最大为 C-1,即特征向量最多有 C-1 个。特征值大的对应的特征向量分割性能最好。

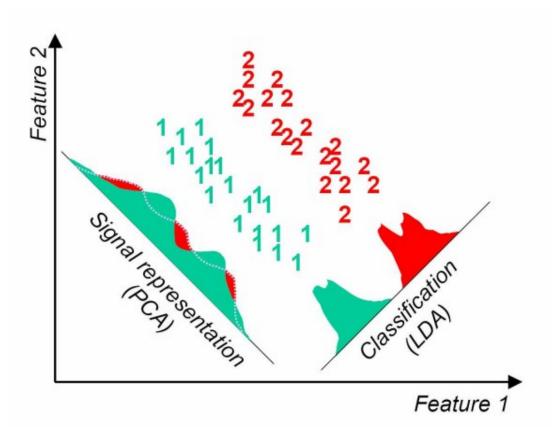
由于 $S_w^{-1}S_B$ 不一定是对称阵,因此得到的 K 个特征向量不一定正交,这也是与 PCA 不同的地方。

## 4. 实例

将 3 维空间上的球体样本点投影到二维上, W1 相比 W2 能够获得更好的分离效果。



PCA 与 LDA 的降维对比:



PCA 选择样本点投影具有最大方差的方向, LDA 选择分类性能最好的方向。

LDA 既然叫做线性判别分析,应该具有一定的预测功能,比如新来一个样例 x,如何确定其类别?

拿二值分来来说,我们可以将其投影到直线上,得到 y,然后看看 y 是否在超过某个阈值 y0,超过是某一类,否则是另一类。而怎么寻找这个 y0 呢?

看

$$y = w^T x$$

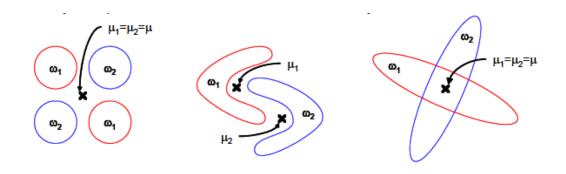
根据中心极限定理,独立同分布的随机变量和符合高斯分布,然后利用极大似然估计求  $P(y|C_i)$ 

然后用决策理论里的公式来寻找最佳的 y0,详情请参阅 PRML。

这是一种可行但比较繁琐的选取方法,可以看第7节(一些问题)来得到简单的答案。

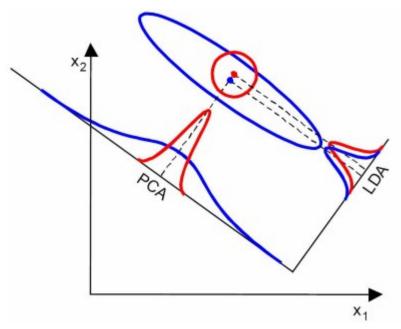
## 5. 使用 LDA 的一些限制

- 1、LDA 至多可生成 C-1 维子空间 LDA 降维后的维度区间在[1,C-1],与原始特征数 n 无关,对于二值分类,最多投影 到 1 维。
- 2、LDA 不适合对非高斯分布样本进行降维。



上图中红色区域表示一类样本,蓝色区域表示另一类,由于是 2 类,所以最多投影到 1 维上。不管在直线上怎么投影,都难使红色点和蓝色点内部凝聚,类间分离。

3、LDA 在样本分类信息依赖方差而不是均值时,效果不好。



上图中,样本点依靠方差信息进行分类,而不是均值信息。LDA 不能够进行有效分类,因为 LDA 过度依靠均值信息。

4、LDA可能过度拟合数据。

## 6. LDA 的一些变种

### 1、非参数 LDA

非参数 LDA 使用本地信息和 K 临近样本点来计算 $S_B$ ,使得 $S_B$ 是全秩的,这样我们可以抽取多余 C-1 个特征向量。而且投影后分离效果更好。

#### 2、正交 LDA

先找到最佳的特征向量,然后找与这个特征向量正交且最大化 fisher 条件的向量。这种方法也能摆脱 C-1 的限制。

- 3、一般化 LDA 引入了贝叶斯风险等理论
- 4、核函数 LDA 将特征 $x \to \Phi(x)$ ,使用核函数来计算。

### 7. 一些问题

上面在多值分类中使用的

$$S_B = \sum_{i=1}^{C} N_i (\mu_i - \mu)(\mu_i - \mu)^T$$

是带权重的各类样本中心到全样本中心的散列矩阵。如果 C=2 (也就是二值分类时) 套用这个公式,不能够得出在二值分类中使用的 $S_{R}$ 。

$$S_B = \sum_{i=1}^{C} (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T$$

因此二值分类和多值分类时求得的 $S_B$ 会不同,而 $S_W$ 意义是一致的。

对于二值分类问题,令人惊奇的是最小二乘法和 Fisher 线性判别分析是一致的。 下面我们证明这个结论,并且给出第 4 节提出的 y0 值得选取问题。

回顾之前的线性回归,给定 N 个 d 维特征的训练样例 $x^{(i)}\{x_1^{(i)},x_2^{(i)},...,x_d^{(i)}\}$ (i 从 1 到 N),每个 $x^{(i)}$ 对应一个类标签 $y^{(i)}$ 。我们之前令 y=0 表示一类,y=1 表示另一类,现在我们为了证明最小二乘法和 LDA 的关系,我们需要做一些改变

$$\begin{cases} y = \frac{N}{N_1}, & \text{样例属于有}N_1 \land \text{元素的类}C_1 \\ y = -\frac{N}{N_2}, & \text{样例属于有}N_2 \land \text{元素的类}C_2 \end{cases}$$

就是将 0/1 做了值替换。 我们列出最小二乘法公式

$$E = \frac{1}{2} \sum_{i=1}^{N} (w^{T} x^{(i)} + w_0 - y^{(i)})^2$$

 $\mathbf{w}$  和 $\mathbf{w}_0$ 是拟合权重参数。 分别对 $\mathbf{w}_0$ 和  $\mathbf{w}$  求导得

$$\sum_{i=1}^{N} (w^{T} x^{(i)} + w_{0} - y^{(i)}) = 0$$

$$\sum_{i=1}^{N} (w^{T} x^{(i)} + w_{0} - y^{(i)}) x^{(i)} = 0$$

从第一个式子展开可以得到

$$w^{T}N\mu + Nw_{0} - \sum_{i=1}^{N} y^{(i)} = w^{T}N\mu + Nw_{0} - \left(N_{1}\frac{N}{N_{1}} - N_{2}\frac{N}{N_{2}}\right) = 0$$

消元后,得

$$w_0 = -w^T \mu$$

$$\mu = \frac{1}{N} \sum_{i=1}^{N} x^{(i)} = \frac{1}{N} (N_1 \mu_1 + N_2 \mu_2)$$

可以证明第二个式子展开后和下面的公式等价

$$\left(S_w + \frac{N_1 N_2}{N} S_B\right) w = N(\mu_1 - \mu_2)$$

其中 $S_w$ 和 $S_B$ 与二值分类中的公式一样。

由于 $S_B$ w =  $(\mu_1 - \mu_2) * \lambda_w$ 

因此,最后结果仍然是

$$w = S_w^{-1}(\mu_1 - \mu_2)$$

这个过程从几何意义上去理解也就是变形后的线性回归(将类标签重新定义),线性回归后的直线方向就是二值分类中 LDA 求得的直线方向 w。

好了,我们从改变后的 y 的定义可以看出 y>0 属于类 $C_1$ ,y<0 属于类 $C_2$ 。因此我们可以选取 y0=0,即如果y(x) =  $w^Tx + w_0 > 0$ ,就是类 $C_1$ ,否则是类 $C_2$ 。

写了好多,挺杂的,还有个 topic 模型也叫做 LDA,不过名字叫做 Latent Dirichlet Allocation,第二作者就是 Andrew Ng 大牛,最后一个他导师 Jordan 泰斗了,什么时候拜读后再写篇总结发上来吧。